

תכונות והיפותזה — מדריך פשוט

מפה פשוטה של נתוני NegoPlay: מה המשמעות של כל עמודה, מה אנחנו מכניסים לנבא, ואיך הכול מתחבר למשא ומתן. כתוב לקורא לא-מומחה.

1. עמודות גולמיות לעומת תכונות — מה ההבדל?

עמודה גולמית (raw column) היא פיסת נתון מוקלטת (כמו "מי ישב בצפון"). **תכונה** (feature) היא מספר המתאר את ההתנהגות של השחקן, מחושב מהעמודות הגולמיות. **מרבית העמודות הגולמיות אינן תכונות** — הן מזהים (IDs), שמות, או החומר הגולמי שממנו אנו מחשבים את התכונות. לבסיס הנתונים הגולמי יש **48 עמודות**. הן מתחלקות ל-4 קבוצות:

קבוצה	דוגמאות לעמודות	האם זו תכונה?	למה
מזהים / מטא-נתונים	match_id, board, round, year, category, competition	לא ❌	פשוט אומר לנו איזה משחק ומתי
שמות שחקנים	open_north, open_south, ..., closed_west (עמודות 8)	לא ❌	פשוט אומר לנו מי ישב איפה
תיעוד משחק גולמי	contract, bidding, tricks, declarer, lead, ns_score, ew_score, 16 עמודות קלפים, vulnerability, dealer	לא ⚠️ באופן ישיר	אלה הם החומר הגולמי — אנו מחשבים תכונות מתוכם
דגלי איכות	has_cards, has_bidding	לא ❌	פשוט אומר "האם המידע הזה זמין או לא"

נקודת מפתח עבור המנחה: מתוך 48 עמודות גולמיות, התכונות מגיעות בעיקר מ-3 בלבד: contract (מה הוכרז), bidding (איך הוכרז), ו-tricks (האם זה הצליח).

2. 10 התכונות שחישבנו

כל תכונה היא **מספר אחד לכל שחקן**, המתאר התנהגות אחת. בנינו 10, בשתי משפחות.

משפחה א' — מתוך עמודת ה- **contract** ("מה השחקן הכריז")

תכונה	משמעות פשוטה	דוגמה
<code>slam_rate</code>	באיזו תדירות הם מכריזים על חוזה ענק (רמה 6–7)	0.10 = מכריז סלאם ב-10% מהזמן
<code>nt_rate</code>	באיזו תדירות הם משחקים ללא שליט (NoTrump)	0.38 = 38% מהחוזים הם NT
<code>partscore_rate</code>	באיזו תדירות הם עוצרים נמוך/בטוח (רמה 1–3)	0.68 = עוצר נמוך ב-68% מהזמן
<code>game_rate</code>	באיזו תדירות הם מכריזים בדיוק על רמת משחק (game level)	—
<code>double_rate</code>	באיזו תדירות החוזה שלהם קיבל דאבל (כפיל)	—

משפחה ב' — מתוך עמודת ה- **bidding** ("איך השחקן הכריז")

תכונה	משמעות פשוטה
<code>opening_rate</code>	באיזו תדירות הם פותחים את המכרז
<code>preempt_rate</code>	באיזו תדירות הם פותחים גבוה (רמה +2) — אגרסיבי
<code>intervention_rate</code>	באיזו תדירות הם מתערבים במכרז של היריבים
<code>penalty_double_rate</code>	באיזו תדירות הם עושים דאבל ליריבים כדי להעניש אותם
<code>avg_bids_per_board</code>	כמה הכרזות (calls) הם מבצעים בכל חלוקה

מה בפועל נכנס למודל: 8 תכונות

השמטנו 2 תכונות מכיוון שהן היו כמעט זהות עבור כולם (הן אינן מפרידות בין שחקנים — "שונות נמוכה"):

- ✗ `avg_level` (כולם ממוצעים סביב ~3.3)
- ✗ `avg_bids_per_board`

אז 8 תכונות שימשו — תחילה ניסינו את K-Means (שנכשל), ואז את שיטת האחוזון-הקיצון שבאמת עבדה (ראו סעיפים 4 ו-7).

3. משתנים בלתי תלויים לעומת משתנים תלויים

- **משתנים בלתי תלויים (ה-x) = הקלטים** שאנו מודדים ומזינים. כאן: **8 תכונות ההתנהגות** (slam_rate , nt_rate , ...). הם "בלתי תלויים" כי הם ניתנים למודל כמו שהם.
- **משתנה תלוי (ה-y) = הפלט** שהמודל מייצר, אשר תלוי בקלטים. כאן: **תווית הפרופיל** (צייד סלאמים, שחקן ביטוח, ...).

משתנה	תפקיד	
x (בלתי תלוי)	8 תכונות ההתנהגות	מה שאנחנו מכניסים פנימה
y (תלוי)	פרופיל השחקן	מה שיוצא החוצה

אנלוגיה פשוטה: x = ציוני המבחנים של תלמיד בכל מקצוע; y = "איזה סוג תלמיד הוא" (מדעי? אמנותי?). הסוג **תלוי** בציונים.

4. הרעיון הגדול: $y = f(x)$ בשתי רמות

כל הדוקטורט הוא שני צעדי $f(x)$ משורשרים יחד.

רמה 1 — בתוך הברידג' (בוצע ☒)

x = how a player bids (the 8 features)
 f = extreme-percentile + binomial test (NOT K-Means)
 y = which behaviour type (Slam Hunter / Insurance / Fighter / NT / Generalist)

במילים: "מתוך איך שאתה מכריז, אנחנו מבינים איזה סוג מקבל-החלטות אתה."

⚠ חשוב — מדוע f אינו K-Means

תחילה ניסינו את K-Means (וגם HDBSCAN ו-GMM) כדי למצוא קבוצות. **הם נכשלו** — השחקנים יוצרים רצף חלק אחד, ולא אשכולות נפרדים (סילואט מקסימלי 0.24; מבנה אשכולות אמיתי דורש $0.5 \leq$). הכישלון הזה הוא בעצמו ממצא. אז ה- f שאנו משתמשים בו בפועל הוא **פרופילינג של אחוזון קיצון (extreme-percentile)**: חיתוך ה-10% העליונים בכל ציר, ואימות בעזרת מבחן מובהקות בינומי ($p < 0.05$).

רמה 2 — מברידג' לעסקים (שאלת המחקר האמיתית — בוצע ☒)

x = the bridge behaviour profile (aggressive? cautious?)
 f = the LLM agent (acts in character)

במילים: "סגנון ההחלטה שלמדנו מברידג' מנבא איך אותו 'אדם' מתנהג במשא ומתן עסקי."

אנו בודקים את רמה 2 ע"י בדיקה האם **דירוג** הפרופילים זהה בשני התחומים, באמצעות **Spearman** ρ (מתאם של דירוגים). יעד: $\rho \geq 0.70$.

סטטוס כן ✓

רמה 1 מוכחת. רמה 2 (שלב 4) הושלמה — ראו **סעיף 8** לתוצאה ρ Spearman עלה מ-0.20 ל-0.80 לאחר שמדד הברידג' תוקן כדי לתגמל את הכפלות העונשין של ה-Fighter).

5. למה זה חשוב לעסקים / משא ומתן

הבעיה בעסקים: נתוני משא ומתן אמיתיים הם **סודיים ולא נמדדים** — אי אפשר לאמן מודל עליהם. ברידג' הוא **מעבדה נקייה** לאותן החלטות (מתי לקחת סיכון, מתי לעצור, מתי ללחוץ על הצד השני), עם 149,000 תוצאות מדידות משחקני עילית.

מה ה-y מאפשר	דוגמה עסקית
לזהות את הסגנון של השותף למשא ומתן	"המנהל הזה מתנהג כמו צייד סלאמים ← צפה להצעות נועזות, הכן הגנה"
לנבא את המהלכים שלהם	"שחקן ביטוח סוגר עסקאות מהר ← אנחנו יכולים ללחוץ למחיר טוב יותר"
לאמן מנהלים בצורה בטוחה	"תרגל מול 5 סוגי מנהלים — אין צורך ביריב אמיתי"

משפט אחד: ברידג' הוא מגרש אימונים מדיד ללמידה וניבוי של סגנונות משא ומתן, בלי צורך בנתונים עסקיים פרטיים.

6. מגבלות ידועות (חשוב להיות גלויים)

1. **רמה 2 הוכחה חלקית** — המעבר מברידג' לעסקים הראה קשר חזק ($\rho=0.80$), אך נשען על $n=5$ פרופילים בלבד, כך שהכוח הסטטיסטי נמוך.
2. **התכונות הן בעיקר תוצאות** — מרבית התכונות מגיעות מהחזקה הסופי, ולא משלבי המכרז צעד-אחר-צעד. רק 5 תכונות ה- **bidding** לוכדות את התהליך. מבקר עשוי להעיר שזה קרוב יותר ל"תוצאה" מאשר ל"תהליך החלטה".
3. **קבוצות פרופיל קטנות** — רק 5 פרופילים, ולכן ל- ρ Spearman יש כוח סטטיסטי נמוך (צריך להיות קרוב ל- ± 1 כדי להיות מובהק).


7. ויזואליזציות: למה K-Means נכשל ואחוזון-קיצון עבד

שלושת האיורים מחושבים חיים מהנתונים האמיתיים של 563 שחקנים ע"י

[notebooks/visualize_clustering_failure.py](#) — שום דבר לא הוקלד ביד, כך שהמספרים אינם

יכולים לסטות מהאמת.

איור 1 — 8 התכונות שנכנסות למודל




8 ההתנהגויות שאנו מודדים לכל שחקן, ממוינות לפי כמה הן **מפרידות** בין השחקנים (מקדם השונות = פיזור ÷ ממוצע). עמודה גבוהה = השחקנים נבדלים הרבה בהתנהגות זו, אז היא עוזרת להבדיל ביניהם. 8 המספרים האלה הם הדבר **היחיד** שהמודל רואה על כל שחקן.

הסבר פשוט 💡

דמיינו שאנחנו מנסים למצוא מה הכי מבדיל בין אנשים. אם נשאל "למי יש שתי עיניים?" כולם יצביעו וזה לא יעזור. אבל אם נשאל "מי אוהב ברוקולי?" — רק חלק יצביעו וזה מפריד ביניהם! עמודה גבוהה = שאלה טובה שמפרידה בין השחקנים.

איור 2 — מדוע K-Means (השיטה הקלאסית) נכשלה



הרצנו K-Means בבקשה ל-2-6 קבוצות (תצורה: 8 תכונות → PCA(3) → StandardScaler, הטובה מבין 5 תצורות שנבדקו). הקו האדום הוא **ציון הסילואט** — כמה נקיות ומופרדות הקבוצות:

- סילואט $0.5 \leq$ = אשכולות אמיתיים ומופרדים (אזור ירוק)
- $0.25 \sim$ = מבנה חלש
- $0.1 \sim$ = למעשה אין אשכולות


כל k מגיע לשיא של **0.24** בלבד — רחוק מ-0.5. שחקני העילית יוצרים **ענן חלק אחד (רצף)**, ולא איים נפרדים. K-Means בנוי למצוא איים; כשאין כאלה הוא פשוט מותח קווים שרירותיים.

💡 הסבר פשוט

ביקשנו מהמחשב לחלק את השחקנים ל"איים" נפרדים לגמרי. הוא נכשל. למה? כי אנשים במציאות הם לא איים נפרדים, אלא רצף רציף. הפס הירוק הוא ציון ה"עובר" כדי להגיד שמצאנו איים, והפס האדום זה מה שהמחשב קיבל — ציון ממש נמוך (0.24).

איור 3 — מדוע שיטת "האחוזון הקיצון" עבדה

Why extreme-percentile SUCCEEDS
each profile = the genuine top-tail of one behaviour axis



ארבעה תרשימים קטנים, אחד לכל פרופיל. אפור = כלל האוכלוסייה על ההתנהגות המגדירה של אותו פרופיל; עמודות צבעוניות = חברי הפרופיל; קו מקווקו = סף ה-10% העליונים. במקום לכפות על הענן קבוצות מזויפות, אנחנו שומרים אותו כמו שהוא ומנקדים את הזנבות הקיצוניים שלו:

- **צייד סלאמים** = הזנב העליון של `slam_rate`
- **שחקן ביטוח** = הזנב העליון של `partscore_rate`
- **לוחם (Fighter)** = הזנב העליון של `penalty_double_rate`
- **מומחה NT** = הזנב העליון של `nt_rate`

כל קבוצה צבעונית יושבת בנקיון בזנב הימני, וכל חבר עובר מבחן מובהקות בינומי ($p < 0.05$), כך שהציון הקיצוני אמיתי ולא מקריות של מדגם קטן.

הסבר פשוט 💡

במקום לנסות למיין את כולם בכוח, פשוט לקחנו רק את ה-10% הכי קיצוניים בכל התנהגות! האפור זה כל האנשים הרגילים במרכז, והפסים הצבעוניים בקצה הם השחקנים הקיצוניים (למשל הכי לוקחי הסיכונים). ככה קל ונוח למצוא פרופילים ברורים!

8. תוצאות שלב 4 – התשובה למחקר

זה החלק הסופי: נתנו לסוכנים לשחק גם ברידג' וגם משא ומתן, ובדקנו אם מי שמנצח בברידג' מנצח גם במשא ומתן. זו שאלת המחקר המרכזית (H3).

מה עשינו בשלב 4


תת-שלב	מה עשינו	המדד
4a – ברידג'	5 הפרופילים הכריזו על 50 ידיים זהות	קרבה ל"חוזה הנכון" לפי כוח היד
4b – משא ומתן	5 הפרופילים ניהלו 4 עסקאות מול "מוכר" קשוח קבוע	כמה הורידו את המחיר
4c – היישור	השוואת הדירוג בשני התחומים	Spearman ρ

מה זה Spearman ρ

מספר בין -1 ל-1 שמוזד אם סדר הפרופילים זהה בשני התחומים. $\rho=1 \rightarrow$ סדר זהה (אישוש). $\rho=0 \rightarrow$ אין קשר. היעד שהוגדר מראש: $\rho \geq 0.70$.

התוצאה – בשני שלבים

שלב ראשון: $\rho = +0.20$ (חלש) – אבל גילינו למה



במידה הראשונה היישור יצא חלש. הסיבה הייתה **חריג אחד — ה-Fighter**: הוא יצא חלש בברידג' אבל **הכי טוב** במשא ומתן, וזה "שבר" את הקשר.


למה? הכישור המגדיר של ה-Fighter הוא **הכפלות עונשין** (penalty doubles) — הוא עשה אותן ב-33% מהכרזותיו, פי 6–8 מכל פרופיל אחר! אבל מדד הברידג' שלנו (שמדד רק "גובה חוזה") היה **עיוור** להכפלות. אז הוא נראה חלש בברידג' למרות שהוא לוחם מצוין. **מומחה הברידג' חזה את זה מראש.**

שלב שני: תיקנו את המדד → $\rho = +0.80$ (מעל היעד!)

בנינו מדד ברידג' **משולב** שמתגמל גם בדיוק בהכרזה וגם לחימה (הכפלות):
 ציון = $0.7 \times \text{דיוק_חוזה} + 0.3 \times \text{שיעור_הכפלות}$. וה- ρ קפץ ל-**0.80** — מעל היעד!

השוואה לפני/אחרי (אותה תמונה בדיוק, רק עם המדד המתוקן):

Correcting the bridge metric pulls the Fighter into line → the alignment appears




שמאל: לפני (par בלבד, $\rho=0.20$) — ה-Fighter חריג. ימין: אחרי (מדד מודע-לחימה, $\rho=0.80$) — כולם מתיישרים.

תראו את ה-Fighter (כתום): **לפני** הוא חריג שיושב גבוה-משמאל (מקום 4 בברידג'); **אחרי** הוא זימינה למקום 2, וכל הנקודות מתיישרות על הקו האלכסוני. ברגע שהמדד התחיל לתגמל את ההכפלות שלו — הקשר הופיע.

💡 ההיפוך היחיד שנשאר (Generalist מול Insurance) — וזה גם ממצא

גם אחרי התיקון נשאר היפוך אחד קטן: שחקן ה-**ביטוח** חלש מ-**Generalist** בברידג', אבל מעט **טוב ממנו** במשא ומתן. זה הגיוני: **שמרנות פוגעת בברידג'** (השחקן מכריז שיטתית נמוך מדי, ולכן דיוק-הפאר שלו יורד) אבל **עוזרת במשא ומתן** (סבלנות וסגירת עסקה יציבה). אותה תכונה עוברת בין התחומים **בכיוון הפוך** — וזו בדיוק הסיבה ש- $\rho=0.80$. זה רעש מוסבר, לא כשל.

וגם ניתוח רגישות — כדי להראות שזה לא תלוי במשקל בודד:



ככל שנותנים יותר משקל ללחימה, ה- ρ עולה. בחרנו משקל מתון (0.3), לא את המקסימלי.

ככל שנותנים יותר משקל ללחימה, ה- ρ עולה (0.20 → 0.60 → 0.80 → 0.90). בחרנו משקל **מתון (0.3)**, לא את המקסימלי — כדי שזה לא ייראה כמו "תפירה" לתוצאה.

למה זה תיקון לגיטימי (ולא רמאות)

1. ה-Fighter **מוגדר** ע"י הכפלות כבר משלב 1 — לא המצאנו זאת עכשיו.
2. המומחה חזה את הבעיה **מראש**, לפני שראינו את ρ .
3. בחרנו משקל מתון (0.3), והקשר יציב בכל משקל סביר.

🎯 המסקנה המתודולוגית (התרומה האמיתית)

מדד ההצלחה בכל תחום חייב לתפוס את הכישור הרלוונטי לאותו תחום. מדדנו את הציר הלא-נכון בברידג', וזה הסתיר קשר חזק שבאמת קיים. ברגע שהמדד תפס את הלחימה — היישור הופיע.

מה זה אומר לדוקטורט

זהו **proof-of-concept מוצלח**: היסוד (זיהוי הפרופילים, H1) חזק ומובהק (Cohen's d 2.1–4.6). שלב 4 (H3) הראה שהקשר קיים ($\rho=0.80$) אך מתחבא מאחורי בעיית מדידה ממוקדת שזיהינו והבנו. כיווני

העבודה לדוקטורט: מדד ברידג' עשיר יותר (או מנוע double-dummy אמיתי), יותר פרופילים, ותרחישי משא ומתן אמיתיים.

⚠️ הסתייגות

$n=5$ פרופילים → כוח סטטיסטי נמוך (p לא מובהק). p הוא אינדיקציה, לא הוכחה. הערך הוא בעיקרון המתודולוגי, לא במספר המדויק.

מסמך ייחוס למנחה. מקור הנתונים: 149,208 שורות 563 EuroBridge (2016–2025); שחקנים כשירים; 8 תכונות אשכול. איורים נוצרו ע"

`python notebooks/visualize_clustering_failure.py` - `python -m src.stage4_simulate.alignment`