

תכונות והיפותזה – מדריך פשוט

מפה פשוטה של נתוני NegoPlay: מה המשמעות של כל עמודה, מה אנחנו מכניסים לנבא, ואיך הכול מתחבר למשא ומתן. כתוב לקורא לא-מומחה.

1. עמודות גולמיות לעומת תכונות – מה ההבדל?

עמודה גולמית (raw column) היא פיסת נתון מוקלטת (כמו "מי ישב בצפון"). **תכונה** (feature) היא מספר המתאר את ההתנהגות של השחקן, מחושב מהעמודות הגולמיות. **מרבית העמודות הגולמיות אינן תכונות** – הן מזהים (IDs), שמות, או החומר הגולמי שממנו אנו מחשבים את התכונות. לבסיס הנתונים הגולמי יש **48 עמודות**. הן מתחלקות ל-4 קבוצות:

קבוצה	דוגמאות לעמודות	האם זו תכונה?	למה
מזהים / מטא-נתונים	match_id, board, round, year, category, competition	לא ❌	פשוט אומר לנו איזה משחק ומתי
שמות שחקנים	open_north, open_south, ..., closed_west (עמודות 8)	לא ❌	פשוט אומר לנו מי ישב איפה
תיעוד משחק גולמי	contract, bidding, tricks, declarer, lead, ns_score, ew_score, vulnerability, dealer, קלפים, 16 עמודות	לא ⚠️ באופן ישיר	אלה הם החומר הגולמי – אנו מחשבים תכונות מתוכם
דגלי איכות	has_cards, has_bidding	לא ❌	פשוט אומר "האם המידע הזה זמין או לא"

נקודת מפתח: מתוך 48 עמודות גולמיות, התכונות מגיעות בעיקר מ-3 בלבד: **contract** (מה הוכרז), **bidding** (איך הוכרז), ו- **tricks** (האם זה הצליח).

2. 10 התכונות שחישבנו

כל תכונה היא **מספר אחד לכל שחקן**, המתאר התנהגות אחת. בנינו 10, בשתי משפחות.

משפחה א' — מתוך עמודת ה- **contract** ("מה השחקן הכריז")

תכונה	משמעות פשוטה	דוגמה
<code>slam_rate</code>	באיזו תדירות הם מכריזים על חוזה ענק (רמה 6-7)	0.10 = מכריז סלאם ב-10% מהזמן
<code>nt_rate</code>	באיזו תדירות הם משחקים ללא שליט (NoTrump)	0.38 = 38% מהחוזים הם NT
<code>partscore_rate</code>	באיזו תדירות הם עוצרים נמוך/בטוח (רמה 1-3)	0.68 = עוצר נמוך ב-68% מהזמן
<code>game_rate</code>	באיזו תדירות הם מכריזים בדיוק על רמת משחק (game level)	—
<code>double_rate</code>	באיזו תדירות החוזה שלהם קיבל דאבל (כפיל)	—

משפחה ב' — מתוך עמודת ה- **bidding** ("איך השחקן הכריז")

תכונה	משמעות פשוטה
<code>opening_rate</code>	באיזו תדירות הם פותחים את המכרז
<code>preempt_rate</code>	באיזו תדירות הם פותחים גבוה (רמה +2) — אגרסיבי
<code>intervention_rate</code>	באיזו תדירות הם מתערבים במכרז של היריבים
<code>penalty_double_rate</code>	באיזו תדירות הם עושים דאבל ליריבים — סופר את כל הדאבלים (הזמנה וגם עונשין); מדד לתחרותיות אגרסיבית (השם מעט מטעה)
<code>avg_bids_per_board</code>	כמה הכרזות (calls) הם מבצעים בכל חלוקה

מה בפועל נכנס למודל: 8 תכונות

השמטנו 2 תכונות מכיוון שהן היו כמעט זהות עבור כולם (הן אינן מפרידות בין שחקנים — "שונות נמוכה"):

- ✗ `avg_level` (כולם ממוצעים סביב ~3.3)
- ✗ `avg_bids_per_board`

אז 8 תכונות שימשו — תחילה ניסינו את K-Means (שנכשל), ואז את שיטת האחוזון-הקיצון שבאמת עבדה (ראו סעיפים 4 ו-7).

3. משתנים בלתי תלויים לעומת משתנים תלויים

- **משתנים בלתי תלויים (ה-x) = הקלטים** שאנו מודדים ומזינים. כאן: **8 תכונות ההתנהגות** (`slam_rate`, `nt_rate`, ...). הם "בלתי תלויים" כי הם ניתנים למודל כמו שהם.
- **משתנה תלוי (ה-y) = הפלט** שהמודל מייצר, אשר **תלוי** בקלטים. כאן: **תווית הפרופיל** (צייד סלאם, שחקן ביטוח, ...).

משתנה	תפקיד	
x (בלתי תלוי)	8 תכונות ההתנהגות	מה שאנחנו מכניסים פנימה
y (תלוי)	פרופיל השחקן	מה שיוצא החוצה

אנלוגיה פשוטה: x = ציוני המבחנים של תלמיד בכל מקצוע; y = "איזה סוג תלמיד הוא" (מדעי? אמנותי?). הסוג **תלוי** בציונים.

4. הרעיון הגדול: $y = f(x)$ בשתי רמות

כל הדוקטורט הוא שני צעדי $f(x)$ משורשרים יחד.

רמה 1 — בתוך הברידג' (בוצע ☒)

x = how a player bids (the 8 features)
 f = extreme-percentile + binomial test (NOT K-Means)
 y = which behaviour type (Slam Hunter / Insurance / Fighter / NT / Generalist)

במילים: "מתוך איך שאתה מכריז, אנחנו מבינים איזה סוג מקבל-החלטות אתה."

⚠ חשוב — מדוע f אינו K-Means

תחילה ניסינו את K-Means (וגם HDBSCAN ו-GMM) כדי למצוא קבוצות. **הם נכשלו** — השחקנים יוצרים רצף חלק אחד, ולא אשכולות נפרדים (סילואט מקסימלי 0.24; מבנה אשכולות אמיתי דורש $0.5 \leq$). הכישלון הזה הוא בעצמו ממצא. אז ה- f שאנו משתמשים בו בפועל הוא **פרופילינג של אחוזון קיצון (extreme-percentile)**: חיתוך ה-10% העליונים בכל ציר, ואימות בעזרת מבחן מובהקות בינומי ($p < 0.05$).

רמה 2 — מברידג' לעסקים (שאלת המחקר האמיתית — בוצע ☒)

x = the bridge behaviour profile (aggressive? cautious?)
 f = the LLM agent (acts in character)

במילים: "סגנון ההחלטה שלמדנו מברידג' מנבא איך אותו 'אדם' מתנהג במשא ומתן עסקי."

אנו בודקים את רמה 2 ע"י בדיקה האם **דירוג** הפרופילים זהה בשני התחומים, באמצעות **Spearman** ρ (מתאם של דירוגים). יעד: $\rho \geq 0.70$.

סטטוס

רמה 1 מוכחת. רמה 2 (שלב 4) הושלמה — ראו **סעיף 8** לתוצאה $\rho = +0.50$ Spearman בין מיומנות ברידג' אמיתית למשא ומתן, ממדידה על הדאטה התחרותי האמיתי).

5. למה זה חשוב לעסקים / משא ומתן

הבעיה בעסקים: נתוני משא ומתן אמיתיים הם **סודיים ולא נמדדים** — אי אפשר לאמן מודל עליהם. ברידג' הוא **מעבדה נקייה** לאותן החלטות (מתי לקחת סיכון, מתי לעצור, מתי ללחוץ על הצד השני), עם 149,000 תוצאות מדידות משחקני עילית.

מה ה-y מאפשר	דוגמה עסקית
לזהות את הסגנון של השותף למשא ומתן	"המנהל הזה מתנהג כמו צייד סלאמים ← צפה להצעות נועזות, הכן הגנה"
לנבא את המהלכים שלהם	"שחקן ביטוח סוגר עסקאות מהר ← אנחנו יכולים ללחוץ למחיר טוב יותר"
לאמן מנהלים בצורה בטוחה	"תרגל מול 5 סוגי מנהלים — אין צורך ביריב אמיתי"

משפט אחד: ברידג' הוא מגרש אימונים מדיד ללמידה וניבוי של סגנונות משא ומתן, בלי צורך בנתונים עסקיים פרטיים.

6. מגבלות ידועות (חשוב להיות גלויים)


1. **רמה 2 הוכחה חלקית** — המעבר מברידג' לעסקים הראה קשר חיובי ($\rho = +0.50$ ב-IMP), אך נשען על $n=5$ פרופילים בלבד, כך שהכוח הסטטיסטי נמוך.
2. **התכונות הן בעיקר תוצאות** — מרבית התכונות מגיעות מהחזקה הסופי, ולא משלבי המכרז צעד-אחר-צעד. רק 5 תכונות ה- **bidding** לוכדות את התהליך.
3. **קבוצות פרופיל קטנות** — רק 5 פרופילים, ולכן ל- ρ Spearman יש כוח סטטיסטי נמוך (צריך להיות קרוב ל- ± 1 כדי להיות מובהק).

4. **המשא ומתן מסומלץ** — אין נתוני משא ומתן אמיתיים, אז הצד הזה הוא הוכחת-היתכנות, לא ולידציה מול מציאות.

7. ויזואליזציות: למה K-Means נכשל ואחוזון-קיצון עבד

שלושת האיורים מחושבים חיים מהנתונים האמיתיים של 563 שחקנים ע"י
— [notebooks/visualize_clustering_failure.py](https://notebooks.visualize_clustering_failure.py) — שום דבר לא הוקלד ביד.

איור 1 — 8 התכונות שנכנסות למודל




8 ההתנהגויות שאנו מודדים לכל שחקן, ממוינות לפי כמה הן **מפרידות** בין השחקנים (מקדם השונות = פיזור ÷ ממוצע). עמודה גבוהה = השחקנים נבדלים הרבה בהתנהגות זו. 8 המספרים האלה הם הדבר היחיד שהמודל רואה על כל שחקן.

הסבר פשוט 💡

דמיינו שאנחנו מנסים למצוא מה הכי מבדיל בין אנשים. אם נשאל "למי יש שתי עיניים?" כולם יצביעו וזה לא יעזור. אבל אם נשאל "מי אוהב ברוקולי?" — רק חלק יצביעו וזה מפריד ביניהם!

איור 2 — מדוע K-Means (השיטה הקלאסית) נכשלה



הרצנו K-Means בבקשה ל-2-6 קבוצות. הקו האדום הוא **ציון הסילואט** — כמה נקיות ומופרדות הקבוצות:

- סילואט ≤ 0.5 = אשכולות אמיתיים ומופרדים (אזור ירוק)
- $0.25 \sim$ = מבנה חלש · $0.1 \sim$ = למעשה אין אשכולות


כל k מגיע לשיא של **0.24** בלבד — רחוק מ-0.5. שחקני העילית יוצרים **ענן חלק אחד (רצף)**, ולא איים נפרדים.

💡 הסבר פשוט

ביקשנו מהמחשב לחלק את השחקנים ל"איים" נפרדים. הוא נכשל כי אנשים במציאות הם רצף רציף, לא איים. הפס הירוק = ציון ה"עובר", והפס האדום = מה שהמחשב קיבל (נמוך, 0.24).

איור 3 — מדוע שיטת "האחוזון הקיצון" עבדה

Why extreme-percentile SUCCEEDS
each profile = the genuine top-tail of one behaviour axis



ארבעה תרשימים, אחד לכל פרופיל. אפור = כלל האוכלוסייה; צבע = חברי הפרופיל; קו מקווקו = סף ה-10% העליונים. במקום לכפות קבוצות מזויפות, אנחנו **מנקדים את הזנבות הקיצוניים**:

- **צייד סלאם** = הזנב העליון של `slam_rate`
- **שחקן ביטוח** = הזנב העליון של `partscore_rate`
- **לוחם (Fighter)** = הזנב העליון של `penalty_double_rate` (דאבלים תוקפניים)
- **מומחה NT** = הזנב העליון של `nt_rate`

הסבר פשוט 💡

במקום למיין את כולם בכוח, לקחנו רק את ה-10% הכי קיצוניים בכל התנהגות! האפור = האנשים הרגילים במרכז, הצבעוני בקצה = השחקנים הקיצוניים. ככה קל למצוא פרופילים ברורים.

8. תוצאות שלב 4 — התשובה למחקר

זה החלק הסופי. שאלת המחקר: האם פרופיל שמנצח בבריג' מנצח גם במשא ומתן?


צעד 1 — לבנות מדד ברידג' שאפשר לסמוך עליו

כדי לענות, היינו צריכים קודם מדד ברידג' **אמין**. הוספנו שני כלים:

1. **מנוע double-dummy** — מנקד חוזה לפי התוצאה **המושלמת** (כשרואים את כל 52 הקלפים). זה הסטנדרט האובייקטיבי בברידג'.

2. **קוף אקראי** — שחקן שמכריז אקראי (אבל חוקי). הוא **חייב** להפסיד; אם לא — המדד לא באמת מודד מיומנות.

הקוף חשף את הבעיה: במדד גס ("באיזו רמה הכרזת") הוא **ניצח** את הפרופילים! זה הוכיח שהמדד שבור. כשניקדנו לפי האם החוזה **באמת מצליח** (double-dummy) — הקוף צנח לתחתית.




כל עמודה = ציון ברידג'; הקוף באדום. שמאל: מדד גס (הקוף מנצח). ימין: double-dummy (הקוף אחרון).

🎯 הקוף כמבחן שפיות

שמאל: הקוף מקבל **0.54** — מעל כל הפרופילים (מדד שבור). ימין: עם double-dummy הקוף צונח ל-**0.10**, אחרון, וכל הפרופילים מנצחים אותו. **המיומנות מנצחת את האקראי — כמו שצריך.**

צעד 2 — למדוד ברידג' מהדאטה האמיתי

הפתרון הנקי ביותר לא דורש סימולציה בכלל: הדאטה כבר מכיל **מכרזים תחרותיים אמיתיים ותוצאות אמיתיות**. אז ניקדנו כל פרופיל לפי **הביצוע התחרותי האמיתי** שלו — איך השחקנים שלו הסתדרו מול השולחן השני על אותם קלפים בדיוק (ניקוד duplicate). זה **סופר הגנה אוטומטית** (הכפלה מוצלחת = ניקוד חיובי), **בלי שום משקל שאנחנו בוחרים**.



מיומנות ברידג' אמיתית (ציר X) מול משא ומתן (ציר Y). התוקפנים (Slam Hunter, Fighter) למעלה-מימין.

🎯 התוצאה: $\rho = +0.50$

קשר חיובי בין מיומנות ברידג' אמיתית למשא ומתן, במדד **IMP** (הסטנדרט בברידג', שמונע מלוח גדול אחד להשתלט). **עמיד** לשינוי קנה-המידה (+0.60 בנקודות גולמיות, אותו דירוג). התוקפנים (Slam Hunter, Fighter) ראשונים **בשני** התחומים; השמרנים מאחור בשניהם. מיומנות בברידג' ובמשא ומתן **זוהי יחד**.

למה זו התוצאה הכי חזקה

- **בלי סימולציה לברידג'** — נתונים תחרותיים אמיתיים מאליפויות אירופה.
- **בלי משקל שרירותי** — הניקוד האמיתי כבר כולל את ערך ההכפלות; אין "למה דווקא X%".

- **ההגנה נספרת לבד** — הכפלה מוצלחת של הלוחם = ניקוד חיובי אמיתי.

⚠ **הסתייגויות כנות**

$n=5$ פרופילים → כוח סטטיסטי נמוך (ק לא מובהק); ρ הוא אינדיקציה, לא הוכחה. **בלבול**
אפשרי: "Slam Hunter" מוגדר לפי **הכרזת** סלאמים, אז ייתכן שהוא משקף בחלקו עוצמת-שחקן כללית, לא רק סגנון. **המשא ומתן מסומלץ** (אין נתוני מו"מ אמיתיים). **היסוד מוצק** — זיהוי הפרופילים מובהק סטטיסטית (Cohen's d 2.1–4.6).

מסמך ייחוס. מקור הנתונים: 149,208 שורות 563 EuroBridge (2016–2025); שחקנים כשירים; 8 תכונות אשכול.