

תכונות והיפותזה – מדריך פשוט

מפה פשוטה של נתוני NegoPlay: מה המשמעות של כל עמודה, מה אנחנו מכניסים לנבא, ואיך הכול מתחבר למשא ומתן. כתוב לקורא לא-מומחה.

1. עמודות גולמיות לעומת תכונות – מה ההבדל?

עמודה גולמית (raw column) היא פיסת נתון מוקלטת (כמו "מי ישב בצפון"). **תכונה** (feature) היא מספר המתאר את ההתנהגות של השחקן, מחושב מהעמודות הגולמיות. **מרבית העמודות הגולמיות אינן תכונות** – הן מזהים (IDs), שמות, או החומר הגולמי שממנו אנו מחשבים את התכונות. לבסיס הנתונים הגולמי יש **48 עמודות**. הן מתחלקות ל-4 קבוצות:

קבוצה	דוגמאות לעמודות	האם זו תכונה?	למה
מזהים / מטא-נתונים	match_id, board, round, year, category, competition	לא ❌	פשוט אומר לנו איזה משחק ומתי
שמות שחקנים	open_north, open_south, ..., closed_west (עמודות 8)	לא ❌	פשוט אומר לנו מי ישב איפה
תיעוד משחק גולמי	contract, bidding, tricks, declarer, lead, ns_score, ew_score, vulnerability, dealer, קלפים, 16 עמודות	לא ⚠️ באופן ישיר	אלה הם החומר הגולמי – אנו מחשבים תכונות מתוכם
דגלי איכות	has_cards, has_bidding	לא ❌	פשוט אומר "האם המידע הזה זמין או לא"

נקודת מפתח: מתוך 48 עמודות גולמיות, התכונות מגיעות בעיקר מ-3 בלבד: **contract** (מה הוכרז), **bidding** (איך הוכרז), ו- **tricks** (האם זה הצליח).

2. 10 התכונות שחישבנו

כל תכונה היא **מספר אחד לכל שחקן**, המתאר התנהגות אחת. בנינו 10, בשתי משפחות.

משפחה א' — מתוך עמודת ה- **contract** ("מה השחקן הכריז")

תכונה	משמעות פשוטה	דוגמה
<code>slam_rate</code>	באיזו תדירות הם מכריזים על חוזה ענק (רמה 6-7)	0.10 = מכריז סלאם ב-10% מהזמן
<code>nt_rate</code>	באיזו תדירות הם משחקים ללא שליט (NoTrump)	0.38 = 38% מהחוזים הם NT
<code>partscore_rate</code>	באיזו תדירות הם עוצרים נמוך/בטוח (רמה 1-3)	0.68 = עוצר נמוך ב-68% מהזמן
<code>game_rate</code>	באיזו תדירות הם מכריזים בדיוק על רמת משחק (game level)	—
<code>double_rate</code>	באיזו תדירות החוזה שלהם קיבל דאבל (כפיל)	—

משפחה ב' — מתוך עמודת ה- **bidding** ("איך השחקן הכריז")

תכונה	משמעות פשוטה
<code>opening_rate</code>	באיזו תדירות הם פותחים את המכרז
<code>preempt_rate</code>	באיזו תדירות הם פותחים גבוה (רמה +2) — אגרסיבי
<code>intervention_rate</code>	באיזו תדירות הם מתערבים במכרז של היריבים
<code>penalty_double_rate</code>	באיזו תדירות הם עושים דאבל ליריבים — סופר את כל הדאבלים (הזמנה וגם עונשין); מדד לתחרותיות אגרסיבית (השם מעט מטעה)
<code>avg_bids_per_board</code>	כמה הכרזות (calls) הם מבצעים בכל חלוקה

מה בפועל נכנס למודל: 8 תכונות

השמטנו 2 תכונות מכיוון שהן היו כמעט זהות עבור כולם (הן אינן מפרידות בין שחקנים — "שונות נמוכה"):

- ✗ `avg_level` (כולם ממוצעים סביב ~3.3)
- ✗ `avg_bids_per_board`

אז 8 תכונות שימשו — תחילה ניסינו את K-Means (שנכשל), ואז את שיטת האחוזון-הקיצון שבאמת עבדה (ראו סעיפים 4 ו-7).

3. משתנים בלתי תלויים לעומת משתנים תלויים

- **משתנים בלתי תלויים (x-ה) = הקלטים** שאנו מודדים ומזינים. כאן: **8 תכונות ההתנהגות** (`slam_rate` , `nt_rate` , ...). הם "בלתי תלויים" כי הם ניתנים למודל כמו שהם.
- **משתנה תלוי (y-ה) = הפלט** שהמודל מייצר, אשר **תלוי** בקלטים. כאן: **תווית הפרופיל** (צייד סלאם, שחקן ביטוח, ...).

משתנה	תפקיד	
x (בלתי תלוי)	8 תכונות ההתנהגות	מה שאנחנו מכניסים פנימה
y (תלוי)	פרופיל השחקן	מה שיוצא החוצה

אנלוגיה פשוטה: x = ציוני המבחנים של תלמיד בכל מקצוע; y = "איזה סוג תלמיד הוא" (מדעי? אמנותי?). הסוג **תלוי** בציונים.

4. הרעיון הגדול: $y = f(x)$ בשתי רמות

כל הדוקטורט הוא שני צעדי $f(x)$ משורשרים יחד.

רמה 1 — בתוך הברידג' (בוצע ☒)

x = how a player bids (the 8 features)
 f = extreme-percentile + binomial test (NOT K-Means)
 y = which behaviour type (Slam Hunter / Insurance / Fighter / NT / Generalist)

במילים: "מתוך איך שאתה מכריז, אנחנו מבינים איזה סוג מקבל-החלטות אתה."

⚠ חשוב — מדוע f אינו K-Means

תחילה ניסינו את K-Means (וגם HDBSCAN ו-GMM) כדי למצוא קבוצות. **הם נכשלו** — השחקנים יוצרים רצף חלק אחד, ולא אשכולות נפרדים (סילואט מקסימלי 0.24; מבנה אשכולות אמיתי דורש $0.5 \leq$). הכישלון הזה הוא בעצמו ממצא. אז ה- f שאנו משתמשים בו בפועל הוא **פרופילינג של אחוזון קיצון (extreme-percentile)**: חיתוך ה-10% העליונים בכל ציר, ואימות בעזרת מבחן מובהקות בינומי ($p < 0.05$).

רמה 2 — מברידג' לעסקים (שאלת המחקר האמיתית — בוצע ☒)

x = the bridge behaviour profile (aggressive? cautious?)
 f = the LLM agent (acts in character)

y = behaviour in a business negotiation

במילים: "סגנון ההחלטה שלמדנו מברידג' מנבא איך אותו 'אדם' מתנהג במשא ומתן עסקי."

אנו בודקים את רמה 2 ע"י בדיקה האם **דירוג** הפרופילים זהה בשני התחומים, באמצעות **Spearman** ρ (מתאם של דירוגים). יעד: $\rho \geq 0.70$.

סטטוס 

רמה 1 מוכחת. רמה 2 (שלב 4) הושלמה — ראו **סעיף 8** לתוצאה $\rho = +0.50$ Spearman בין מיומנות ברידג' אמיתית למשא ומתן, ממדידה על הדאטה התחרותי האמיתי).

5. למה זה חשוב לעסקים / משא ומתן

הבעיה בעסקים: נתוני משא ומתן אמיתיים הם **סודיים ולא נמדדים** — אי אפשר לאמן מודל עליהם. ברידג' הוא **מעבדה נקייה** לאותן החלטות (מתי לקחת סיכון, מתי לעצור, מתי ללחוץ על הצד השני), עם 149,000 תוצאות מדידות משחקני עילית.

מה ה-y מאפשר	דוגמה עסקית
לזהות את הסגנון של השותף למשא ומתן	"המנהל הזה מתנהג כמו צייד סלאמים ← צפה להצעות נועזות, הכן הגנה"
לנבא את המהלכים שלהם	"שחקן ביטוח סוגר עסקאות מהר ← אנחנו יכולים ללחוץ למחיר טוב יותר"
לאמן מנהלים בצורה בטוחה	"תרגל מול 5 סוגי מנהלים — אין צורך ביריב אמיתי"

משפט אחד: ברידג' הוא מגרש אימונים מדיד ללמידה וניבוי של סגנונות משא ומתן, בלי צורך בנתונים עסקיים פרטיים.

6. מגבלות ידועות (חשוב להיות גלויים)


1. **רמה 2 הוכחה חלקית** — המעבר מברידג' לעסקים הראה קשר חיובי ($\rho = +0.50$ ב-IMP), אך נשען על $n=5$ פרופילים בלבד, כך שהכוח הסטטיסטי נמוך.
2. **התכונות הן בעיקר תוצאות** — מרבית התכונות מגיעות מהחזקה הסופי, ולא משלבי המכרז צעד-אחר-צעד. רק 5 תכונות ה- **bidding** לוכדות את התהליך.
3. **קבוצות פרופיל קטנות** — רק 5 פרופילים, ולכן ל- ρ Spearman יש כוח סטטיסטי נמוך (צריך להיות קרוב ל- ± 1 כדי להיות מובהק).

4. **המשא ומתן מסומלץ** — אין נתוני משא ומתן אמיתיים, אז הצד הזה הוא הוכחת-היתכנות, לא ולידציה מול מציאות.

7. ויזואליזציות: למה K-Means נכשל ואחוזון-קיצון עבד

שלושת האיורים מחושבים חיים מהנתונים האמיתיים של 563 שחקנים ע"י
— [notebooks/visualize_clustering_failure.py](https://notebooks.visualize_clustering_failure.py) — שום דבר לא הוקלד ביד.

איור 1 — 8 התכונות שנכנסות למודל




8 ההתנהגויות שאנו מודדים לכל שחקן, ממוינות לפי כמה הן **מפרידות** בין השחקנים (מקדם השונות = פיזור ÷ ממוצע). עמודה גבוהה = השחקנים נבדלים הרבה בהתנהגות זו. 8 המספרים האלה הם הדבר היחיד שהמודל רואה על כל שחקן.

הסבר פשוט 💡

דמיינו שאנחנו מנסים למצוא מה הכי מבדיל בין אנשים. אם נשאל "למי יש שתי עיניים?" כולם יצביעו וזה לא יעזור. אבל אם נשאל "מי אוהב ברוקולי?" — רק חלק יצביעו וזה מפריד ביניהם!

איור 2 — מדוע K-Means (השיטה הקלאסית) נכשלה



הרצנו K-Means בבקשה ל-2-6 קבוצות. הקו האדום הוא **ציון הסילואט** — כמה נקיות ומופרדות הקבוצות:

- סילואט ≤ 0.5 = אשכולות אמיתיים ומופרדים (אזור ירוק)
- $0.25 \sim$ = מבנה חלש · $0.1 \sim$ = למעשה אין אשכולות


כל k מגיע לשיא של **0.24** בלבד — רחוק מ-0.5. שחקני העילית יוצרים **ענן חלק אחד (רצף)**, ולא איים נפרדים.

💡 הסבר פשוט

ביקשנו מהמחשב לחלק את השחקנים ל"איים" נפרדים. הוא נכשל כי אנשים במציאות הם רצף רציף, לא איים. הפס הירוק = ציון ה"עובר", והפס האדום = מה שהמחשב קיבל (נמוך, 0.24).

איור 3 — מדוע שיטת "האחוזון הקיצון" עבדה

Why extreme-percentile SUCCEEDS
each profile = the genuine top-tail of one behaviour axis



ארבעה תרשימים, אחד לכל פרופיל. אפור = כלל האוכלוסייה; צבע = חברי הפרופיל; קו מקווקו = סף ה-10% העליונים. במקום לכפות קבוצות מזויפות, אנחנו **מנקדים את הזנבות הקיצוניים**:

- **צייד סלאם** = הזנב העליון של `slam_rate`
- **שחקן ביטוח** = הזנב העליון של `partscore_rate`
- **לוחם (Fighter)** = הזנב העליון של `penalty_double_rate` (דאבלים תוקפניים)
- **מומחה NT** = הזנב העליון של `nt_rate`

הסבר פשוט 💡

במקום למיין את כולם בכוח, לקחנו רק את ה-10% הכי קיצוניים בכל התנהגות! האפור = האנשים הרגילים במרכז, הצבעוני בקצה = השחקנים הקיצוניים. ככה קל למצוא פרופילים ברורים.

8. שלב 4 — איך הגענו לתשובה (צעד אחר צעד)


החלק הזה מספר, בכנות מלאה, איך הגענו למסקנה — כולל טעות בדרך שתיקנו. השאלה: האם הסגנון של שחקן ברידג' עובר למשא ומתן? הגענו לתשובה ב-שני שלבים.

צעד 1 — שאלנו קודם "מי שמנצח פה מנצח שם?" → יצא חלש

התחלנו מהשאלה הכי טבעית: האם מי שמנצח בברידג' מנצח גם במו"מ? כדי שמדד הברידג' יהיה אמין, הוספנו שני כלים:

1. **קוף אקראי** — שחקן שמכריז אקראי בלי לחשוב. הוא **חייב להפסיד**; אם הוא מנצח — המדד שבור (מבחן שפיות).
2. **מנוע double-dummy** — מחשב את התוצאה המושלמת של חוזה מתוך כל 52 הקלפים (בלי לשחק).


הקוף מיד חשף בעיה: במדד הישן (הגס) הוא **ניצח** את כל המומחים! רק כשניקדנו לפי האם החוזה באמת מצליח (double-dummy) הקוף צנח לתחתית:



שמאל: מדד גס — הקוף (אדום) מנצח את כולם (שבור). ימין: double-dummy — הקוף אחרון. מיומנות מנצחת.

איך בנינו את הקוף בפועל? על 2,000 לוחות אמיתיים, נתנו לקוף להכריז חוזה אחד אקראי (כמו לשלוח פתק מכובע — נניח "6NT", בלי להסתכל על הקלפים). מנוע ה-double-dummy חישב אם החוזה מצליח לפי 52 הקלפים, וקיבלנו IMP 7- בממוצע — אסון. כך נראה **אפס-מיומנות** (הקוף לא שיחק קלפים ולא עלה כסף).

אחר כך מדדנו את הברידג' מהדאטה האמיתי — איך כל פרופיל באמת הסתדר באליפויות (ביחידות IMP, מול השולחן השני על אותם קלפים). כדי לראות את כל התמונה בנינו "סרגל מיומנות": מהקוף (רצפה) ועד המשחק המושלם (תקרה).



שמאל: הקוף (IMP -7, רצפה), שחקני העילית (סביב 0), והמשחק המושלם / double-dummy (+1.1, תקרה). ימין (זום): בין הפרופילים — Slam Hunter ו-Fighter ראשונים.

צד הברידג' מוצק

שחקני העילית רחוקים מאוד מהקוף (-7) — כולם מיומנים — אך עדיין מתחת למשחק המושלם (+1.1; אפילו אלופים משאירים ~1 IMP על השולחן). זהו מדד ברידג' אמין: מבוסס נתונים אמיתיים, חסין-קוף, ובלי משקל שרירותי.

אבל — כשהשוונו את הניצחון בברידג' מול הניצחון במו"מ, ה-q יצא חלש ולא יציב: קפץ בין +0.2 ל-0.9- לפי בחירת המדד.


⚠ למה הניצחון יצא חלש?

כי "מי מנצח" תלוי ביריב ובחוקי המשחק — לא רק בשחקן. זה רועש מדי כדי להיות התשובה. הבנו שמדדנו את הדבר הלא-נכון.

צעד 2 — הבנו: לא "ניצחון", אלא סגנון

השאלה האמיתית מעולם לא הייתה "מי מנצח" — אלא האם הסגנון עובר: שחקן תוקפני בברידג', האם הוא לוחץ חזק גם במו"מ? אז מדדנו תוקפנות ישירות:

- **תוקפנות בברידג'** = כמה סלאמים + פתיחות גבוהות + דאבלים (מהנתונים האמיתיים).
- **תוקפנות במו"מ** = כמה נמוך הסוכן פותח (לוחץ על המחיר).



תוקפנות בבריג' (ציר X) מול תוקפנות במו"מ (ציר Y). Fighter תוקפני בשניהם; Insurance שמרן בשניהם.


התוצאה: $\rho = +0.80$

הסגנון **עובר חזק!** תוקפני בבריג' = תוקפני במו"מ. זה **מעל היעד (0.70)** — ובדיוק **שאלת המחקר המקורית** ("התאמה התנהגותית $\leq 70\%$ ").

צעד 3 — ודאנו שזו לא "רמאות" (טאוטולוגיה)

חשש לגיטימי: אולי הסוכן תוקפני במו"מ **רק כי קראנו לו "תוקפני"**? כדי לבדוק, עשינו **בקרת פרומפט-הפוך**: נתנו לכל פרופיל את **הכישורים של ההפוך** (לפייטר נתנו כישורי-ביטוח שמרניים, ולהיפך), ומדדנו שוב.

Style transfers — and it is the SKILLS that carry it (anti-tautology control)




שמאל (תואם): $\rho = +0.80$. ימין (הפוך): כשחליפים כישורים — הקשר מתהפך ל- -0.90 . ההתנהגות עוקבת אחרי הכישורים.

עבר! לא טאוטולוגיה ✓

הקשר **התהפך ל- -0.90** ! הפייטר עם כישורי-ביטוח נהיה **פחות** תוקפני; הביטוח עם כישורי-פייטר נהיה **יותר** תוקפני. כלומר התוקפנות עוקבת אחרי הכישורים (מהברידג'), לא אחרי השם. ה- $+0.80$ אמיתי ומבוסס-כישורים.

צעד 4 — עיגנו במציאות (נתוני משא ומתן אמיתיים)

כדי שהמו"מ לא יהיה שרירותי, בדקנו **5,247 משא-ומתנים אמיתיים** מ-Craigslist (אנשים אמיתיים על מחירים). גילינו ש**תוקפנות משתלמת** שם, והמוכרים כמעט לא עוזבים — וכך כיילנו את המוכר בסימולציה לפי המציאות.



5,247 מו"מ אמיתיים: ככל שהקונה פותח תוקפני יותר, הוא תופס יותר עודף — ואחוז העסקאות כמעט לא יורד.

המסקנה הסופית 🏆

הסגנון עובר חזק ($\rho = +0.80$, מאומת ולא-טאוטולוגי); הניצחון רועש ($\rho \approx +0.2$). כלומר: שחקן תוקפני בברידג' יתנהג תוקפני במו"מ — אבל אם זה ינצח תלוי בתחום. שאלת המחקר המקורית (התאמה התנהגותית) — נענתה בחיוב.

הסתייגויות כנות ⚠️

n=5 פרופילים → כוח סטטיסטי נמוך (ק לא מובהק); ק הוא אינדיקציה. **המשא ומתן מסומלץ** (אין נתוני מו"מ אמיתיים של אותם שחקנים). הוכחה מלאה דורשת בקרה בקנה-מידה גדול ונתוני מו"מ אמיתיים (שנה 2). **היסוד מוצק** — זיהוי הפרופילים מובהק (Cohen's d 2.1–4.6).

9. מילון מונחים — כל מה שעשינו, במילים פשוטות

לקורא שלא מכיר ברידג' או סטטיסטיקה: כל מונח שהשתמשנו בו, עם דוגמה פשוטה.

מונח	מה זה	דוגמה פשוטה
חוזה (contract)	הבטחה כמה לקיחות תיקח (רמה N = הבטחה ל-N+6 לקיחות)	"♠4" = הבטחה לקחת 10 לקיחות
סלאם (slam)	חוזה רמה 6-7 — שאפתני, בונוס ענק, סיכון גבוה	"6NT" = להבטיח 12 לקיחות מתוך 13
דאבל / הכפלה	מהלך תחרותי שמכפיל את הנקודות; "עונשין" = "אני בטוח שתיכשל"	היריב הכריז, אתה אומר "דאבל" ומפיל אותו
double-dummy	מחשב שיודע את כל 52 הקלפים ומחשב את התוצאה המושלמת (בלי לשחק)	"אם משחקים 6NT מושלם — מצליח או נופל?"
קוף (monkey)	שחקן ללא אסטרטגיה שמכריז אקראי. חייב להפסיד — אחרת המדד שבור	שולף הכרזה אקראית מכובע
datum	ממוצע שני השולחנות על אותו לוח (כל לוח משוחק פעמיים) = "שחקן ממוצע"	שולחנות עם 0 ו-50 → datum = 25
IMP	בכמה ניצחת בלוח מול השולחן השני, בסולם דחוס (לוח גדול לא משתלט)	ניצחון קטן = 2+ IMP; סלאם = 13+ IMP
Spearman ρ	מספר בין 1- ל-1: האם סדר השחקנים זהה בשני התחומים	אם A>B>C בשניהם → ρ=+1
Cohen's d	גודל אפקט — בכמה סטיות-תקן הפרופיל נבדל מהממוצע (0.8 כבר "גדול")	d=2.1 → הפרדה כמעט מלאה
תוקפנות (סגנון)	כמה השחקן "לוחץ": בברידג' = הרבה סלאם/דאבלים; במו"מ = פתיחה במחיר נמוך	Fighter = תוקפני; Insurance = שמרן
ניצחון מול סגנון	"ניצחון" = מי גבר (תלוי ביריב, רועש). "סגנון" = איך התנהג (יציב)	הסגנון עובר (0.80+); הניצחון רועש (0.2+)
בקרת פרומפט-הפוך	נותנים לפרופיל את הכישורים של ההפוך — אם ההתנהגות מתהפכת, היא נובעת מהכישורים (לא מהשם)	פייטר+כישורי-ביטוח → נהיה שמרן

טאוטולוגיה	"מסקנה מעגלית" — לגלות מה שכבר הנחנו. הבקרה מוודאת שלא נפלנו לזה	"הוא תוקפני כי קראנו לו תוקפני" = טאוטולוגיה
------------	---	---

כל הסיפור — בשורה 💡

בנינו מדד ברידג' מוצק (קוף + **double-dummy** + דאטה אמיתי). מתאם ה**ניצחון** יצא חלש
($\rho \approx +0.2$). זיקקנו לשאלה הנכונה — **סגנון** ↔ **סגנון** → $\rho = +0.80$. בקרת פרומפט-הפוך
($\rho \rightarrow -0.90$) הוכיחה שזה **לא טאוטולוגי**. עיגנו ב-5,247 מו"מ אמיתיים מ-Craigslist.

10. איך לאמת כל תוצאה בעצמך (שקיפות + הוכחות)

כל הקוד נמצא ב-`repo`. לכל ממצא: הפקודה להרצה, מה היא בודקת, והפלט האמיתי שהיא מייצרת (ההוכחה). הריצי בעצמך מתיקיית `NegoPlay/` ותקבלי בדיוק את אותם מספרים.

הוכחה 1 — הקוף חשף שהמדד הישן שבור

בודק: מריץ קוף אקראי ומשווה מדד ישן (גס) מול חדש (double-dummy).

```
python -m notebooks.visualize_metric_fix
```

הפלט האמיתי:

```
monkey: {'old': 0.536, 'new': 0.096}
Slam Hunter      old=0.510  new=0.355
Insurance Player  old=0.324  new=0.724
```

← הקוף **0.54** במדד הישן (מנצח את כולם!), **0.10** בחדש (אחרון). זו ההוכחה.

הוכחה 2 — הסרגל: קוף (-7) ← עילית ← מושלם (1.1+)

בודק: מחשב על 2,000 לוחות אמיתיים את ציון הקוף ואת ה-double-dummy המושלם (ביחידות IMP).

```
python -m notebooks.visualize_real_skill_spectrum
```

הפלט האמיתי:

```
monkey -6.93 IMP | perfect +1.13 IMP | n=2000 boards
Slam Hunter    +0.172 IMP
Fighter        +0.085 IMP
```

הוכחה 3 — סגנון → סגנון: $\rho = +0.80$

בודק: מתאם תוקפנות-ברידג' (מהנתונים האמיתיים) מול תוקפנות-מו"מ (מהלוגים).

```
python -m notebooks.style_alignment
```

הפלט האמיתי:

profile	bridge_aggression	nego_aggression
Fighter	1.301	0.808
Slam Hunter	0.511	0.760
NT Specialist	-0.359	0.771
Generalist	-0.685	0.666
Insurance Player	-0.768	0.666

Spearman rho = +0.800 (p = 0.104, n = 5)

הוכחה 4 — בקרת פרומפט-הפוך: $-0.90 \rightarrow \rho$

בודק: נותן לכל פרופיל את כישורי ההפוך ומודד שוב (דורש קריאות ~0.1 LLM).

```
python -m notebooks.inverse_prompt_control
```

הפלט האמיתי:

```
Fighter          1.301   0.725 (skills <- Insurance Player)
Insurance Player -0.768   0.805 (skills <- Fighter)
MATCHED rho = +0.80
INVERSE rho = -0.90 (p=0.037)
=> aggression FOLLOWED THE SWAPPED SKILLS, not the label. PASS.
```

הוכחה 5 — Craigslist: תוקפנות משתלמת (5,247 מו"מ אמיתיים)

בודק: מנתח 5,247 מו"מ אמיתיים — האם פתיחה תוקפנית תופסת יותר עודף ומפוצצת עסקאות.

```
python -m notebooks.validate_negotiation_features
```

הפלט האמיתי:

opening aggressiveness	n	deal_rate	avg_surplus
soft (open near ask)	665	0.85	0.66
firm (open at target)	1457	0.86	0.68
lowball (below target)	1796	0.83	1.02

← lowball תופס הכי הרבה עודף (1.02), ואחוז העסקאות כמעט לא יורד (0.83). זו ההוכחה שתוקפנות משתלמת.

איפה הכל נשמר 📁

קוד: `NegoPlay/notebooks/` -| `NegoPlay/src/` · **תוצאות:** `NegoPlay/results/stage4/` (קבצי CSV/JSON גולמיים) · **תמונות:** `NegoPlay/docs/images/` · הכל ב-Git (היסטוריה מלאה של כל

מסמך ייחוס. מקור הנתונים: 149,208 שורות 563; EuroBridge (2016–2025) שחקנים כשירים; 8 תכונות אשכול.