

שאלות ותשובות

מה עשינו עד כה — בקצרה

- שאלת המחקר: האם סגנון קבלת-ההחלטות של שחקן ברידג' מנבא את התנהגותו במשא ומתן עסקי? הברידג' הוא מעבדה, היעד הוא מו"מ עסקי.
- הנתונים: 149,208 שורות מתחרויות ברידג' אירופאיות (2016–2025); אחרי סינון נשארו 563 שחקנים עם מספיק נתונים (≤ 50 ידיים).
- שלב 1 — גילוי פרופילים: חישבנו 8 תכונות התנהגות לכל שחקן. ניסינו K-Means לחלק לקבוצות — נכשל (הנתונים הם רצף, לא אשכולות). במקום זה השתמשנו באחוזון-קיצון + מבחן בינומי וקיבלנו 4 פרופילים + "כללי".
- שלב 2 — חילוף כישורים: מודל שפה (LLM) קרא את משחקי כל פרופיל והפיק 5–7 כישורים מאפיינים.
- שלב 3 — בניית סוכנים: כל פרופיל הפך לסוכן LLM עם "כרטיס אופי" (הכישורים מהברידג', לא תיוג שהמצאנו).
- שלב 4 — סימולציה כפולה: כל סוכן שיחק גם ברידג' וגם משא ומתן עסקי; השווינו את דירוג המנצחים בשני התחומים עם Spearman ρ .
- התוצאה: מדד ברידג' ראשוני נתן $\rho=0.20$ (חלש) בגלל חריג אחד; אחרי תיקון המדד $\rightarrow \rho=0.80$ (מעל היעד 0.70). היסוד מובהק (Cohen's d 2.1–4.6).
- הסתייגות מרכזית: $n=5$ פרופילים $\rightarrow$ כוח סטטיסטי נמוך. ρ הוא אינדיקציה, והתרומה האמיתית היא מתודולוגית.

ברידג' ב-90 שניות

- המשחק: 4 שחקנים, 2 זוגות (אתה ושותפך מול 2 יריבים). כל אחד מקבל 13 קלפים.
- המכרז (bidding): לפני המשחק יש "מכרז" — כל זוג מבטיח כמה לקיחות (tricks) ייקח. ההבטחה המנצחת נקראת חוזה (contract).
- רמות 1–7: חוזה ברמה N = הבטחה לקחת $6+N$ לקיחות. רמה גבוהה = הבטחה שאפתנית ומסוכנת.

- **מונחי המפתח שלנו: סלאם** = חוזה רמה 6-7 (שאפתני, בונוס ענק, סיכון גבוה) · $part-score$ = חוזה נמוך 1-3 (בטוח, שמרני) · $NT (NoTrump)$ = משחק בלי "צבע מנצח" · דאבל / הכפלה = הימור שמכפיל את הנקודות; הכפלת עונשין = "אני בטוח שהיריב ייכשל בחוזה שלו".
- **HCP (כוח יד):** נקודות לפי קלפים גבוהים (אס=4, מלך=3, מלכה=2, נסיך=1). מודד כמה היד "חזקה".
- **פאר (par):** החוזה האופטימלי תאורטית לחלוקת קלפים נתונה — "מה היה נכון להכריז".

חלק א' — תכונות, נתונים, ויחידת הניתוח

ש: אילו פיצ'רים

ת: 10 תכונות התנהגות לכל שחקן, ב-2 משפחות; 8 מהן נכנסו למודל. כל תכונה היא **שיעור** (יחס בין 0 ל-1).

מתוך "מה הוכרז" (חוזה)	מתוך "איך הוכרז" (מכרז)
$slam_rate$ — שיעור חוזי סלאם	$opening_rate$ — שיעור פתיחת מכרז
nt_rate — שיעור חוזי NT	$preempt_rate$ — פתיחה גבוהה (אגרסיבי)
$partscore_rate$ — שיעור עצירה נמוך/בטוח	$intervention_rate$ — התערבות במכרז היריב
$game_rate$ — שיעור חוזי "משחק"	$penalty_double_rate$ — הכפלות עונשין
$double_rate$ — שיעור חוזים שהוכפלו	$avg_bids_per_board$ — מס' הכרזות לחלוקה

ש: מהי יחידת הניתוח? מהו n?

ת: יחידת הניתוח היא **שחקן בודד**. $n = 563$ **שחקנים** שעברו סף כשירות (≤ 50 ידיים שהכריזו עליהן וגם ≤ 50 ידיים עם נתוני מכרז). כל שחקן הוא וקטור של 8 מספרים.

ש: איך בחרת אילו תכונות להכניס? למה 8 ולא 10?

ת: הסרנו 2 תכונות עם **שוונות נמוכה** — מקדם השוונות ($CV = \text{סטיית תקן} \div \text{ממוצע}$) קטן מ-0.10. תכונה שכמעט זהה אצל כולם לא מבדילה בין שחקנים, אז היא רק מוסיפה רעש.

דוגמה: avg_level — כל שחקני העילית מכריזים בממוצע סביב רמה 3.3. אם לכולם אותו ערך, התכונה חסרת תועלת לסיווג, כמו לשאול "למי יש שתי עיניים?".

ש: האם התכונות מתואמות ביניהן? יש כפילויות?

ת: בדקנו מטריצת מתאמים והסרנו כפילויות. בנוסף, לפני האשכול הרצנו **PCA** (3 רכיבים) שמייצר צירים אורתוגונליים — כך שגם אם נשאר מתאם שיורי, האשכול עצמו עבד על מרחב לא-מתואם.

הערה סטטיסטית: זו גם הסיבה שאנחנו מדווחים על PCA(3) כתצורה הטובה ביותר מתוך 5 שנבדקו — היא מנטרלת קורלציה ומפחיתה ממדיות לפני K-Means.

חלק ב' — למה K-Means נכשל ומהו "רצף"

ש: למה K-Means נכשל? (השאלה ששאל בפעם הקודמת)

ת: K-Means מחפש **קבוצות נפרדות** ("איים"). בנתונים שלנו אין איים — יש ענן רציף אחד. מדד ה**סילואט** (silhouette) הגיע לכל היותר ל-**0.24**, בעוד שמבנה אשכולות אמיתי דורש $0.5 \leq$. ניסינו $k=2$ עד 6 — כולם נכשלו.

הערה סטטיסטית: סילואט מודד לכל נקודה כמה היא קרובה לאשכול שלה לעומת האשכול השכן: $s = (b-a)/\max(a,b)$. ערך סביב 0 = הנקודה על הגבול בין אשכולות = אין הפרדה אמיתית.

ש: מה זה "רצף" (continuum)? (השאלה ששאל בפעם הקודמת)

ת: רצף = הנתונים משתנים בהדרגה חלקה, בלי קפיצות או פערים שמפרידים קבוצות. אין "סוגים", יש **ספקטרום**.

דוגמה פשוטה: גובה של אנשים הוא רצף — אין שתי קבוצות נפרדות "נמוכים" ו"גבוהים" עם פער ביניהן; יש מעבר חלק מ-150 ל-200 ס"מ. לעומת זאת **סוג דם** (A/B/AB/O) הוא קטגוריות נפרדות = אשכולות אמיתיים. שחקני הברידג' שלנו הם כמו גובה, לא כמו סוג דם.


ש: איך את יודעת שזה באמת רצף, ולא שפשוט בחרת k לא נכון?

ת: 3 ראיות מתכנסות: (1) **כל** k מ-2 עד 6 נתן סילואט ≥ 0.24 ; (2) ניסינו גם **HDBSCAN** (שלא מניח מספר אשכולות מראש) וגם **GMM** — שניהם נכשלו; (3) ויזואלית, מפת ה-PCA מראה ענן יחיד בלי פערים. שלוש שיטות שונות שמסכימות = לא ארטיפקט של פרמטר בודד.

ש: אם K-Means נכשל — איך בכל זאת הגדרת פרופילים?

ת: בשיטת **אחוזון-קיצון (extreme-percentile)**: במקום לחתוך את הענן לקבוצות מזויפות, לקחנו את ה-**10% העליונים** בכל ציר התנהגות, ואישרנו כל קבוצה במבחן מובהקות בינומי.

דוגמה: "צייד סלאמים" = ה-10% עם שיעור הסלאם הגבוה ביותר. "לוחם" = ה-10% עם הכי הרבה הכפלות עונשין. זה לא ממיין את כולם בכוח — זה מנקד את הזנבות הקיצוניים של הרצף.



K-Means: כל k נותן סילואט ~0.24, הרחק מתחת ל-0.5 הנדרש. אין אשכולות אמיתיים.

ש: המבחן הבינומי — בשביל מה הוא, ולמה $p < 0.05$?

ת: הוא מאשר שהציון הקיצוני של שחקן הוא **אמיתי ולא מקריות של מדגם קטן**. השאלה: "בהינתן השיעור הבסיסי באוכלוסייה, מה ההסתברות שהשחקן הזה הגיע לשיעור כה גבוה במקרה?". אם $p < 0.05$ — לא סביר שזה מקרה, אז הוא באמת שייך לפרופיל.


דוגמה: אם השיעור הבסיסי של סלאם הוא 5.5%, ושחקן עשה סלאם ב-10% מתוך 200 ידיים — המבחן הבינומי שואל אם 10% מתוך 200 חורג מובהקית מ-5.5%. כן → הוא "צייד סלאמים" אמיתי.

ש: בדקת הרבה שחקנים והרבה צירים — מה עם בעיית ההשוואות המרובות?

ת: שאלה מצוינת וצפויה ממנו. כן, זה רלוונטי: 563 שחקנים $\times$ כמה צירים = הרבה מבחנים. הדרכים שלנו: (1) סף שמרני (10% עליונים **וגם** $p < 0.05$, לא רק אחד מהם); (2) גדלי האפקט הם **עצומים** (Cohen's d 2.1–4.6) — הם שורדים כל תיקון סביר; (3) נשמח ליישם תיקון **FDR (Benjamini-Hochberg)** אם הוא ימליץ — זה לא ישנה את הפרופילים בגלל גודל האפקט.

המסר לסטטיסטיקאי: "אני מודעת לבעיית ה-multiple comparisons; האפקטים כל כך גדולים שהם עמידים, ואני פתוחה ליישם FDR."

Why extreme-percentile SUCCEEDS
each profile = the genuine top-tail of one behaviour axis



כל פרופיל = הזנב הימני (10% העליונים) של ציר התנהגות אחד. אפור=כלל האוכלוסייה, צבע=הפרופיל.

חלק ג' — ולידציה של הפרופילים

ש: מה זה Cohen's d ולמה הערכים 4.6–2.1 חשובים?

ת: Cohen's d מודד **גודל אפקט** — בכמה סטיות-תקן נבדל הפרופיל מהממוצע. $d=0.8$ כבר נחשב "גדול". הערכים שלנו **4.6–2.1** הם עצומים — הפרדה כמעט מלאה בין הפרופיל לשאר.

דוגמה: $d=2.1$ פירושו שכמעט כל "צייד סלאם" נמצא מעל כמעט כל שחקן רגיל בציר הסלאם. החפיפה זעירה.

ש: גדלי הקבוצות קטנים (20, 21, 37...) — זו בעיה?

ת: לוולידציה של שלב 1 — לא, כי גודל האפקט עצום וה- p מובהק גם ב- n קטן. הקבוצות: צייד סלאם 20, ביטוח 21, לוחם 37, מומחה NT 17, והשאר (הרוב) "כללי", מתוך 563.

הערה: ה- n הקטן n הופך לבעיה בשלב 4, כששאלת היחידה היא הפרופיל ($n=5$). שם נדבר על כוח סטטיסטי.

חלק ד' — המשא ומתן, התהליך, והיישור (שלב 4)

ש: איך עובד המשא ומתן? מי מנהל אותו?

ת: כל פרופיל (סוכן LLM) משחק **קונה** ב-4 תרחישים עסקיים, מול **מוכר קבוע שאינו LLM** — המוכר הוא נוסחה: מוותר בהדרגה לכיוון "רצפה" ולא מתחת לה. כך ההבדלים שמדדנו נובעים מהקונה (הפרופיל), לא מרעש של מוכר משתנה.

דוגמה לתרחיש: רכישת חברת SaaS — מחיר הוגן 9M, המוכר פותח ב-13M, רצפה 8M. הקונה מנסה להוריד מחיר ככל האפשר עד 4 סבבים.

ש: איך מוגדר "ניצחון" בכל תחום?

ת: **בברידג':** כמה קרוב השחקן הכריז ל"חוזה הנכון" (par) לפי כוח היד. **במו"מ:** איזה אחוז מהפער מחיר תפס הקונה — (פתיחה - רצפה) / (פתיחה - מחיר סופי). בשני המקרים: מספר בין 0 ל-1, ממוצע על כל הידיים/התרחישים.

ש: מה זה ρ Spearman ולמה לא ρ Pearson?

ת: ρ Spearman הוא מתאם על **דירוגים** (מי ראשון, שני...), לא על הערכים עצמם. בחרנו בו כי השאלה שלנו היא על **סדר**: "האם אותו פרופיל שמנצח בברידג' מנצח גם במו"מ?". הוא גם עמיד לחריגים ולא מניח קשר ליניארי.

דוגמה: אם הדירוג בברידג' הוא $A > B > C$ והדירוג במו"מ גם $\rho = 1$ — $A > B > C$, גם אם הערכים המוחלטים שונים לגמרי.

ש: $n=5$ פרופילים — מה עם כוח סטטיסטי? ה- ρ לא מובהק!


ת: נכון, וזו ההסתייגות המרכזית שלנו, שאנחנו **מציינים מפורשות**. עם $n=5$, גם $\rho=0.80$ נותן $p \approx 0.10$. לכן אנחנו אומרים ש- ρ הוא **אינדיקציה ולא הוכחה**, והתרומה האמיתית היא **מתודולוגית** (ראי השאלה הבאה). זה proof-of-concept, והדוקטורט ירחיב את ה- n .

המסר: "אני לא טוענת למובהקות; אני טוענת לעיקרון מתודולוגי שהודגם, עם תוכנית להגדיל את ה- n ."

ש: שינית את המדד אחרי שראית את התוצאה — זה לא p-hacking?

ת: השאלה הכי חשובה שלו, ויש לנו תשובה חזקה. **לא**, מ-3 סיבות: (1) ה"לוחם" מוגדר ע"י הכפלות כבר משלב 1 — המדד המתוקן פשוט מודד את הכישור המגדיר שלו עצמו; (2) **מומחה הברידג'** **חזה את הבעיה מראש**, לפני שראינו את (3) p ; בחרנו משקל **מתון (0.3)**, לא את זה שממקסם את p (0.4 היה נותן 0.90), והצגנו **ניתוח רגישות** מלא.

המסר לסטטיסטיקאי: "התיקון הוא a-priori ומוגדר-תאורטית, לא חיפוש אחורה. דיווחתי משקל מתון + sensitivity analysis כדי להראות שזה לא garden-of-forking-paths."



לפני (par בלבד, $\rho=0.20$) מול אחרי (מדד מודע-לחימה, $\rho=0.80$). ה-Fighter (כתום) זז אל האלכסון.

ש: למה נשאר היפוך בין Insurance ל-Generalist?

ת: זה ההיפוך היחיד שמחזיק את p על 0.80 ולא 1.0, וזה **ממצא ולא רעש**: שחקן ה"ביטוח" (השמרן) חלש יותר בברידג' אבל חזק יותר במו"מ. **שמרנות פוגעת בברידג'** (מכריז נמוך מדי → דיוק נמוך) אבל **עוזרת במו"מ** (סבלנות, סגירת עסקה יציבה). אותה תכונה עוברת בכיוון הפוך בין התחומים.

ש: איך התמודדת עם זה שה-LLM לא דטרמיניסטי?

ת: גם ב-temperature=0 ה-LLM נותן תשובות שונות (ריצה מקבילית על GPU). הפתרון: כל יד רצה **3 פעמים** והוכרעה **בהצבעת רוב**; כל פלט גולמי נשמר ל-JSONL. הרפרודוקטיביות היא ברמת **המדגם** (התפלגות על הרבה ידיים), לא ברמת הקריאה הבודדת.

ש: איך מנעת "תאום מלאכותי" — שה-LLM פשוט מציית לפרומפט?

ת: הזרקנו לסוכנים רק את הכישורים **שנגזרו מהברידג'** (כמו "הכפלת עונשין אגרסיבית"), אף פעם לא מילות אופי שהמצאנו (כמו "תהיה אגרסיבי"). יש גם **בקרת פרומפט הפוך** מתוכננת: אם פרופיל הפוך נותן יישור גבוה באותה מידה — סימן שזה ציות ולא העברה אמיתית.

חלק ה' — התמונה הגדולה והדוקטורט

ש: למה ברידג' בכלל? איך זה קשור לעסקים?

ת: נתוני משא ומתן אמיתיים **סודיים ולא נמדדים** — אי אפשר לאמן עליהם מודל. ברידג' הוא מעבדה נקייה לאותן החלטות (מתי לקחת סיכון, מתי לעצור, מתי ללחוץ), עם 149K תוצאות מדידות. אם הפרופיל מהברידג' מנבא מו"מ — קיבלנו דרך ללמוד אסטרטגיה עסקית בלי נתונים פרטיים.

ש: מה התרומה אם המספר לא מובהק?

ת: התרומה היא **מתודולוגית**: מדד ההצלחה בכל תחום חייב לתפוס את הכישור הרלוונטי לאותו תחום. מדדנו את הציר הלא-נכון בברידג' וזה הסתיר קשר אמיתי; ברגע שהמדד תפס את הלחימה — הקשר הופיע. זה עיקרון שמתקף את עצמו ולא תלוי ב-n.

ש: מה הצעדים הבאים לדוקטורט?

ת: (1) להגדיל את ה-n — יותר פרופילים ויותר תרחישים, כדי להגיע למובהקות; (2) מדד ברידג' עשיר יותר או מנוע double-dummy אמיתי במקום קירוב הפאר; (3) תרחישי מו"מ אמיתיים יותר; (4) בקרת הפרומפט-ההפוך בפועל.

💡 **טיפ אחרון לפגישה:** אם הוא לוחץ על נקודה סטטיסטית — אל תתגונני. תגידי "נקודה טובה, אני מודעת לזה, וזו בדיוק הסיבה ש-X". כל ההסתייגויות (n קטן, p-hacking, multiple comparisons) כבר **מתועדות מראש** במסמכים שלך — זה מראה בגרות מחקרית.