

הכנה לפגישה עם דר' רמי — שאלות ותשובות

מסמך הכנה אישי. דר' רמי הוא סטטיסטיקאי (לכן התשובות הסטטיסטיות מדויקות ונוקבות), אבל לא מכיר ברידג' (לכן כל מונח ברידג' מוסבר בפשטות). לכל שאלה: תשובה קצרה, ואם צריך — דוגמה או הערה סטטיסטית.

מה עשינו עד כה — בקצרה

- שאלת המחקר:** האם סגנון קבלת-ההחלטות של שחקן ברידג' מנבא את התנהגותו במשך ומתן עסקי? הבריידג' הוא מעבדה, היעד הוא מו"מ עסקי.
- הנתונים:** 149,208 שורות מתחרויות ברידג' אירופאיות (2016–2025); אחרי סינון נשארו 563 שחקנים עם מספיק נתונים (≤ 50 ידיים).
- שלב 1 — גילוי פרופילים:** חישבנו 8 תכונות התנהגות לכל שחקן. ניסינו K-Means לחלק לקבוצות — נכשל (הנתונים רצף, לא אשכולות). במקום זה השתמשנו באחוזון-קיצון + מבחן בינומי וקיבלנו 4 פרופילים + "כללי".
- שלב 2 — חילוף כישורים:** מודל שפה (LLM) קרא את משחקי כל פרופיל והפיק 5–7 כישורים מאפיינים.
- שלב 3 — בניית סוכנים:** כל פרופיל הפך לסוכן LLM עם "כרטיס אופי" (הכישורים מהבריידג', לא תיוג שהמצאנו).
- שלב 4 — סימולציה כפולה:** כל סוכן שיחק גם ברידג' וגם משך ומתן עסקי; השווינו את דירוג המנצחים עם Spearman ρ .
- התוצאה:** מדד ברידג' ראשוני נתן $\rho=0.20$ (חלש) בגלל חריג אחד; אחרי תיקון המדד $\rho=0.80$ (מעל היעד 0.70). היסוד מובהק (Cohen's d 2.1–4.6).
- הסתייגות מרכזית:** $n=5$ פרופילים → כוח סטטיסטי נמוך. ρ הוא אינדיקציה, והתרומה האמיתית היא מתודולוגית.

בריידג' ב-90 שניות (כדי שתוכלי לענות לו על הבסיס)

- המשחק:** 4 שחקנים, 2 זוגות (אתה ושותפך מול 2 יריבים). כל אחד מקבל 13 קלפים.
- המכרז (bidding):** לפני המשחק יש "מכרז" — כל זוג מבטיח כמה לקיחות (tricks) ייקח. ההבטחה המנצחת נקראת חוזה (contract).
- רמות 1–7:** חוזה ברמה N = הבטחה לקחת $N+6$ לקיחות. רמה גבוהה = הבטחה שאפתנית ומסוכנת.

- **מונחי המפתח שלנו:** סלאם = חוזה רמה 6-7 (שאפתני, סיכון גבוה) $\cdot$ $part-score$ = חוזה נמוך 1-3 (בטוח, שמרני) $\cdot$ NT = משחק בלי "צבע מנצח" $\cdot$ דאבל = מהלך תחרותי במכרז (ראו השאלה הייעודית בהמשך — יש לו שני סוגים).
- **HCP (כוח יד):** נקודות לפי קלפים גבוהים (אס=4, מלך=3, מלכה=2, נסיך=1). מודד כמה היד "חזקה".
- **פאר (par):** החוזה האופטימלי תאורטית לחלוקת קלפים נתונה — "מה היה נכון להכריז".

חלק א' — תכונות, נתונים, ויחידת הניתוח

ש: אילו פיצ'רים (תכונות) יש לך? (השאלה ששאל בפעם הקודמת)

ת: 10 תכונות התנהגות לכל שחקן, ב-2 משפחות; 8 מהן נכנסו למודל. כל תכונה היא **שיעור** (יחס בין 0 ל-1).

מתוך "מה הוכרז" (חוזה)	מתוך "איך הוכרז" (מכרז)
$slam_rate$ — שיעור חוזי סלאם	$opening_rate$ — שיעור פתיחת מכרז
nt_rate — שיעור חוזי NT	$preempt_rate$ — פתיחה גבוהה (אגרסיבי)
$partscore_rate$ — שיעור עצירה נמוך/בטוח	$intervention_rate$ — התערבות במכרז היריב
$game_rate$ — שיעור חוזי "משחק"	$penalty_double_rate$ — שיעור דאבלים (כל הסוגים)
$double_rate$ — שיעור חוזים שהוכפלו	$avg_bids_per_board$ — מס' הכרזות לחלוקה

ש: מהי יחידת הניתוח? מהו n?

ת: יחידת הניתוח היא **שחקן בודד**. $n = 563$ **שחקנים** שעברו סף כשירות ($50 \leq$ ידיים שהכריזו עליהן וגם $50 \leq$ ידיים עם נתוני מכרז). כל שחקן הוא וקטור של 8 מספרים.

ש: איך בחרת אילו תכונות להכניס? למה 8 ולא 10?

ת: הסרנו 2 תכונות עם **שוונות נמוכה** — מקדם השונות ($CV = \text{סטיית תקן} \div \text{ממוצע}$) קטן מ-0.10. תכונה שכמעט זהה אצל כולם לא מבדילה בין שחקנים.

דוגמה: `avg_level` — כל שחקני העילית מכריזים בממוצע סביב רמה 3.3. אם לכולם אותו ערך, התכונה חסרת תועלת — כמו לשאול "למי יש שתי עיניים?".

ש: האם התכונות מתואמות ביניהן? (מולטי-קולינאריות)

ת: כן, בדקנו. "תכונות מתואמות" = שתי תכונות שמודדות כמעט אותו דבר, אז אחת מהן מיותרת. עשינו 2 דברים: (1) הסתכלנו על טבלה שמראה אילו תכונות "כפולות" וזרקנו אותן; (2) הרצנו **PCA** — טכניקה שמכווצת את התכונות לכמה "צירים חדשים" שלא חופפים זה לזה.

דוגמה: "גובה בסנטימטרים" ו"גובה באינצ'ים" הן לא שתי תכונות — זו אותה תכונה פעמיים. בדיוק את הכפילויות האלה זרקנו.

חלק ב' — למה K-Means נכשל ומהו "רצף"

ש: למה K-Means נכשל? (השאלה ששאל בפעם הקודמת)

ת: K-Means מחפש **קבוצות נפרדות** ("איים"). בנתונים שלנו אין איים — יש ענן רציף אחד. מדד ה**סילואט** הגיע לכל היותר ל-0.24, בעוד שמבנה אשכולות אמיתי דורש $0.5 \leq$. ניסינו $k=2$ עד 6 — כולם נכשלו.

הערה סטטיסטית: סילואט מודד לכל נקודה כמה היא קרובה לאשכול שלה לעומת השכן: $s = (b-a)/\max(a,b)$. ערך סביב 0 = הנקודה על הגבול = אין הפרדה אמיתית.

ש: מה זה "רצף" (continuum)? (השאלה ששאל בפעם הקודמת)

ת: **רצף** = הנתונים משתנים בהדרגה חלקה, בלי קפיצות שמפרידות קבוצות. אין "סוגים", יש **ספקטרום**.

דוגמה: **גובה** הוא רצף — אין פער ריק בין "נמוכים" ל"גבוהים", יש מעבר חלק. **סוג דם** (A/B/AB/O) הוא קטגוריות נפרדות עם פערים = אשכולות אמיתיים. השחקנים שלנו כמו גובה, לא כמו סוג דם.

ש: אבל אפשר לחתוך גובה ל-150/160/170 — זה לא קבוצות?


ת: אפשר, אבל החיתוך **מלאכותי** — את ממציאה אותו, הוא לא קיים בטבע. ההבדל: האם יש "חורים ריקים" בין הקבוצות. בגובה אין חור (יש אנשים בכל ערך), אז אדם 159 ו-160 כמעט זהים אבל "נחתכו" לקבוצות שונות. בסוג דם יש חורים אמיתיים — אף אחד לא "בין A ל-B".

המבחן: אם אזיז את קו החיתוך קצת והתוצאה משתנה — אין קבוצות אמיתיות. הסילואט הנמוך (0.24) מאשר שאין מבנה טבעי, אז עברנו לזיהוי הקצוות במקום אפשר.

ש: אם K-Means נכשל — איך הגדרת פרופילים?

ת: באחוזון-קיצון: לקחנו את ה-10% העליונים בכל ציר התנהגות, ואישרנו במבחן בינומי. זה לא ממיין את כולם בכוח — זה מנקד את הזנבות הקיצוניים של הרצף.

דוגמה: "צייד סלאם" = ה-10% עם הכי הרבה סלאמים. "לוחם" = ה-10% עם הכי הרבה דאבלים.



K-Means: כל k נותן סילואט ~0.24, הרחק מתחת ל-0.5 הנדרש. אין אשכולות אמיתיים.

ש: המבחן הבינומי — בשביל מה, ולמה $p < 0.05$?

ת: הוא מאשר שהציון הקיצוני של שחקן **אמיתי ולא מקרה** של מדגם קטן. השאלה: "בהינתן השיעור הבסיסי באוכלוסייה, מה ההסתברות להגיע לשיעור כה גבוה במקרה?". $p < 0.05$ → לא מקרה.


דוגמה: שיעור סלאם בסיסי ~5.5%; שחקן עשה 10% מתוך 200 ידיים. המבחן בודק אם 200/10% חורג מובהקית מ-5.5%.

ש: בדקת הרבה שחקנים וצירים — מה עם השוואות מרובות?

ת: שאלה צפויה. כן רלוונטי. הדרכים שלנו: (1) סף שמרני (10% עליונים וגם $p < 0.05$); (2) גדלי האפקט **עצומים** (Cohen's d 2.1–4.6) — שורדים כל תיקון; (3) נשמח ליישם **FDR (Benjamini-Hochberg)** — לא ישנה את הפרופילים בגלל גודל האפקט.

המסר: "אני מודעת ל-multiple comparisons; האפקטים עמידים, ואני פתוחה ל-FDR".

Why extreme-percentile SUCCEEDS each profile = the genuine top-tail of one behaviour axis



כל פרופיל = הזנב הימני (10% העליונים) של ציר התנהגות אחד. אפור=כלל האוכלוסייה, צבע=הפרופיל.

חלק ג' — ולידציה של הפרופילים

ש: מה זה Cohen's d ולמה הערכים 4.6–2.1 חשובים?

ת: Cohen's d מודד **גודל אפקט** — בכמה סטיות-תקן נבדל הפרופיל מהממוצע. $d=0.8$ כבר "גדול". הערכים שלנו 4.6–2.1 — הפרדה כמעט מלאה.

דוגמה: $d=2.1$ → כמעט כל "צייד סלאם" מעל כמעט כל שחקן רגיל בציר הסלאם. החפיפה זעירה.

ש: גדלי הקבוצות קטנים (20, 21, 37...) — בעיה?

ת: לוולידציה של שלב 1 — לא, כי גודל האפקט עצום וה- p מובהק גם ב- n קטן. הקבוצות: צייד סלאם 20, ביטוח 21, לוחם 37, מומחה NT 17, והשאר "כללי", מתוך 563.

הערה: ה- n הקטן n הופך לבעיה בשלב 4, כששאלת היחידה היא הפרופיל ($n=5$).

חלק ד' — הדאבלים, הפייטר, והכובע ההגנתי

ש: מה זה "דאבל", ויש לו סוגים?

ת: דאבל הוא מהלך תחרותי במכרז (מסומן x), ויש לו שני סוגים שונים לגמרי:

סוג	משמעות	שכיחות
דאבל עונשין	"היריב יכשל בחוזה — אני מעניש אותו" (נגד היריב)	נדיר
דאבל הזמנה (takeout)	"שותף, בוא תכריז משהו" (שיתופי עם השותף)	נפוץ

אותה מילה (x), שתי כוונות הפוכות.

ש: ⚠ התכונה נקראת penalty_double_rate — היא סופרת רק עונשין?

ת: לא — וזו הערת דיוק חשובה. בדקנו בקוד: התכונה סופרת את כל הדאבלים (גם הזמנה וגם עונשין), לא רק עונשין. השם מטעה. אבל זה בסדר: שני הסוגים הם בחירה להיכנס ולהילחם במכרז במקום לפסוח, אז המדד תקף לתחרותיות אגרסיבית. השם המדויק: "דאבלר תוקפני", לא "מעניש". המספרים ו- p לא משתנים — רק השם.

המסר לבוחן ברידג': "33% דאבלי עונשין היה לא ריאלי — אבל 33% דאבלים מכל סוג הגיוני לשחקן תחרותי. הסיגנל אמיתי, רק השם דורש דיוק."

ש: למה דאבל הוא תכונה של פייטר? כולם עושים דאבל הזמנה...

ת: המפתח: לא "האם עושה דאבל" אלא "כמה הרבה". הפייטר ב-10% העליונים — פי 2-4 מהממוצע. הרבה דאבלים (מכל סוג) = שחקן שלא מוותר, כל הזמן נכנס לקרב במקום לפסוח. זה הסגנון התוקפני.

אנלוגיה: שחקן כדורסל שעושה עבירות פי 3 מכולם — את יודעת שהוא אגרסיבי, בלי קשר לסוג העבירה.

ש: הפיצ'רים מתייחסים להתקפה או להגנה?

ת: לשניהם, אבל לא מאוזן. רוב הפיצ'רים הם התקפה (החוזה שהשחקן הכריז: סלאם/NT/partscore). 2 פיצ'רים הגנתיים: $intervention_rate$ - $penalty_double_rate$ (דאבל = פעולה הגנתית, להפיל את היריב).

מגבלה כנה: כל הפיצ'רים הם משלב המכרז בלבד — אין לנו נתוני משחק-קלפים, אז "הגנה בשולחן" לא נמדדת. כיוון לדוקטורט.

חלק ה' — המשא ומתן, התהליך, והיישור (שלב 4)

ש: איך עובד המשא ומתן? מי מנהל אותו?

ת: כל פרופיל (סוכן LLM) משחק **קונה** ב-4 תרחישים עסקיים, מול **מוכר קבוע שאינו LLM** (נוסחה: מוותר בהדרגה לכיוון "רצפה"). כך ההבדלים נובעים מהקונה, לא מרעש של מוכר משתנה.

דוגמה: רכישת SaaS — הוגן 9M, המוכר פותח 13M, רצפה 8M. הקונה מנסה להוריד מחיר עד 4 סבבים.

ש: איך מוגדר "ניצחון" בכל תחום?

ת: **בברידג':** כמה קרוב השחקן הכריז ל"חוזה הנכון" (par). **במו"מ:** איזה אחוז מהפער תפס הקונה — (פתיחה - רצפה)/(פתיחה - סופי). שניהם בין 0 ל-1, ממוצע על כל הידיים/התרחישים.

ש: מה זה ρ Spearman ולמה לא ρ Pearson?

ת: ρ Spearman הוא מתאם על **דירוגים**, לא על הערכים. השאלה שלנו על **סדר**: "מי שמנצח בברידג' מנצח גם במו"מ?". הוא עמיד לחריגים ולא מניח קשר ליניארי.

דוגמה: אם בברידג' $A > B > C$ וגם במו"מ $A > B > C \rightarrow \rho = 1$, גם אם הערכים שונים.

ש: $n=5$ פרופילים — כוח סטטיסטי? ה- ρ לא מובהק!


ת: נכון, וזו ההסתייגות המרכזית שאני **מציינת מפורשות**. עם $n=5$ גם $\rho=0.80$ נותן $p \approx 0.10$. לכן ρ הוא **אינדיקציה ולא הוכחה**, והתרומה היא **מתודולוגית**.

המסר: "אני לא טוענת למובהקות; אני טוענת לעיקרון מתודולוגי שהודגם, עם תוכנית להגדיל את ה- n ."

ש: שינית את המדד אחרי שראית את התוצאה — זה לא p-hacking?

ת: השאלה הכי חשובה. לא, מ-3 סיבות: (1) ה"לוחם" מוגדר ע"י דאבלים כבר משלב 1 — המדד מודד את הכישור שלו עצמו; (2) מומחה הברידג' חזה את הבעיה מראש, לפני שראינו (3) ρ ; בחרנו משקל מתון (0.3), לא הממקסם (0.4 היה נותן 0.90), והצגנו ניתוח רגישות.

המסר: "התיקון a-priori ומוגדר-תאורטית, לא חיפוש אחורה. משקל מתון + sensitivity analysis מונעים garden-of-forking-paths".



לפני (par בלבד, $\rho=0.20$) מול אחרי (מדד מודע-לחימה, $\rho=0.80$). ה-Fighter (כתום) זז אל האלכסון.

ש: למה נשאר היפוך בין Insurance ל-Generalist?

ת: ההיפוך היחיד שמחזיק את ρ על 0.80 ולא 1.0, וזה ממצא: שחקן ה"ביטוח" (השמרן) חלש בברידג' אבל חזק במו"מ. שמרנות פוגעת בברידג' (מכריז נמוך מדי) אבל עוזרת במו"מ (סבלנות, סגירה יציבה). אותה תכונה עוברת בכיוון הפוך.

ש: איך התמודדת עם אי-הדטרמיניזם של ה-LLM?

ת: גם ב-temperature=0 ה-LLM נותן תשובות שונות (GPU מקבילי). הפתרון: כל יד רצה 3 פעמים והוכרעה בהצבעת רוב; כל פלט נשמר ל-JSONL. הרפרודוקטיביות ברמת המדגם, לא הקריאה הבודדת.

ש: למה ברידג' בכלל? איך זה קשור לעסקים?

ת: נתוני מו"מ אמיתיים **סודיים ולא נמדדים**. ברידג' הוא מעבדה נקייה לאותן החלטות (מתי לקחת סיכון, מתי לעצור, מתי ללחוץ), עם 149K תוצאות מדידות. אם הפרופיל מהברידג' מנבא מו"מ — קיבלנו דרך ללמוד אסטרטגיה עסקית בלי נתונים פרטיים.

ש: מה התרומה אם המספר לא מובהק?

ת: **מתודולוגית:** מדד ההצלחה בכל תחום חייב לתפוס את הכישור הרלוונטי לאותו תחום. מדדנו ציר לא-נכון בברידג' וזה הסתיר קשר אמיתי; ברגע שהמדד תפס את הלחימה — הקשר הופיע. עיקרון שמתקף את עצמו ולא תלוי ב-n.

ש: מה הצעדים הבאים לדוקטורט?

ת: (1) להגדיל את ה-n (יותר פרופילים ותרחישים) למובהקות; (2) מדד ברידג' עשיר יותר / מנוע double-dummy; (3) **הפרדת דאבל הזמנה מעונשין**; (4) נתוני משחק-קלפים (הגנה בשולחן); (5) בקרת פרומפט-הפוך בפועל.

💡 **טיפ אחרון לפגישה:** אם הוא לוחץ על נקודה — אל תתגונני. "נקודה טובה, אני מודעת, וזו בדיוק הסיבה ש-X". כל ההסתייגויות (n קטן, multiple comparisons, p-hacking, שם הדאבל) כבר **מתועדות מראש** — זה מראה בגרות מחקרית.

מסמך הכנה אישי. מבוסס על: `features_and_hypothesis.md`, `RESEARCH_INSIGHTS.md`,

`alignment_corrected_report.md`, ופרק התוצאות ב- `main.tex`. נתונים: 149,208 שורות 563; EuroBridge; שחקנים; 8

תכונות; 5 פרופילים.